仲恺农业工程学院

毕业论文（设计）开题报告

基于网络爬虫和 Lucene 的食谱搜索引擎设计

姓　　名	周炜竣
学　　院	信息科学与技术学院
专业班级	信息管理与信息系统 192 班
学　　号	201910234234
校内指导教师	陈勇
职称/职务	副教授
校外指导教师	朱政华
职称/职务	高级工程师
起始时间	2022 年 10 月 18 日

仲恺农业工程学院教务部制

一、开题依据（研究目的、意义及国内外研究概况，附主要参考文献）

1.1 研究目的

1.1.1 垂直搜索引擎

随着互联网的发展，万维网（WWW）成为一种互联网的最重要的应用之一，用户能够通过各网站的网页与服务器之间交互，享受着各种信息服务。早期各种网站层出不穷，网页的数量海量，使得用户难以定位到想要的网络资源。而如 Google、百度这类基于关键词搜索的通用搜索引擎的出现，很好解决的这样的问题，如今通用搜索引擎已经有非常成熟的基础架构；能够根据用户输入关键词，快速从海量的网页资源中返回高相关性的结果。

但碍于通用搜索引擎的底层逻辑是需要尽量大的广度，要尽量把互联网上几乎所有网页囊括其中，顾虑到信息面的“广”度，而不是“深”度；这使得其在专业领域的搜索精度下降，如今在使用“百度”查询专业领域的信息时，往往不能得到满意的结果。

为了解决通用搜索引擎对专业领域检索效果差的问题，聚焦于某个领域、针对某一类人群的搜索引擎应运而生，也就是垂直搜索引擎。

1.1.2 食谱资源整合

随着各种网络平台的发展，再结合如今自媒体的浪潮，食谱资源已经由早期的集中于食谱网站分散到各大公共平台，且这些平台各具特色且开放，有的平台甚至对美食主题设立独立的分区；如 bilibili 美食区，大众点评美食交流区，短视频平台（如抖音、快手等）美食教学系列短视频，小红书美食笔记，YouTube 等等。

同时在各大公共平台，美食是如今的一个热议的主题，存在大量的受众群体；食谱更是其中的核心内容。再加上网络上食谱资源数量众多，载体形式多样，人们对食谱学习的需求较高。

1.1.3 缺乏完备的基于用户的食谱检索功能

并不是所有的用户都有充分的条件去制作大部分菜谱的美食，每个用户的实际情况不同，并不能纯面向食谱来给用户提供信息。这也是大部分食谱网站相对欠缺的功能，往往对食谱进行简单的分文别类作为主要的发现菜品的方式，往往只能根据一个条件（例如菜式、某一个食材、某一种烹饪方式），需要一种组合查询机制。

另一方面在检索功能上除了像传统菜谱那样，根据如食材、调料、火候、口味、炊具、烹饪时间的典型的菜谱指标外，还需要面向用户的检索。例如，用户已有的

食材能做什么菜品？用户在已有的食材的基础上能够后续提供某类食材后又能做什么菜品？用户忌口哪些食材？用户的预算有限能做的菜谱有哪些？菜谱对应的做法正宗吗？

1.2 国内外研究概况

1.2.1 搜索引擎的发展历程

国内外已经历多代搜索引擎的迭代：

（1）第一代搜索引擎（目录搜索引擎）：人工方式或半自动方式搜集信息，由编辑员查看信息之后，人工形成信息摘要，并将信息置于事先确定的分类框架中。信息大多面向网站，提供目录浏览服务和直接检索服务。如今这种形式的搜索引擎依旧存在，如国内的 hao123、国内搜狐、新浪、网易等，国外则有 Yahoo!等。
目录搜索引擎只是搜索引擎的一种表现形式，并不会因为出现早而被淘汰，如今有些通用搜索引擎也会结合目录搜索引擎使得搜索服务更便捷。

（2）第二代搜索引擎开始（全文搜索引擎）：开始根据用户输入的关键词进行搜索。能够根据一定的策略、运用特定的计算机程序从互联网上搜集信息，在对信息进行组织和处理后，为用户提供检索服务，将用户检索相关的信息展示给用户的系统。

这一代开始的搜索引擎才被称为真正意义上的搜索引擎。随着人工智能技术的发展与应用，使得搜索引擎越来越智能，越来越能理解用户，理解信息的能力越来越接近人类。

除此之外，还有元搜索引擎（聚合其他通用搜索引擎的检索结果的搜索引擎），以及本次毕业设计准备实现的垂直搜索引擎。

1.2.2 国内的垂直搜索引擎案例

（1） 自身仅为内容的整合者：

① 视频搜索：一般通用搜索引擎内置（如百度、Google、搜狗等）。

② 图片搜索：一般通用搜索引擎内置（如百度图片、Google 图片、必应壁纸等）。

（2） 自身能作为内容的提供者（站内搜索引擎）：

① 视频搜索：bilibili、优酷等。

② 地图搜索：百度地图、Google 地图、高德地图等。

③ 美食搜索：大众点评、饿了么、美团等。

④ 新闻搜索：今日头条、百度资讯、各类门户网站等。

⑤ 公众号搜索：搜狗微信（微信提供相关接口）、微信。

参 考 文 献

[1]夏菁.移动互联网时代青年的美食社交[D].安徽大学:2019.

[2]刘琼宇,刘擎业,宋易欣,朱磊,宋雪瑶.互联网美食平台发展现状及对策——以菜谱类美食应用为例[J].现代食品,2017(01):31-35. DOI:10.16736/j.cnki.cn41-1434/ts.2017.01.011.

[3]张弘弦,田玉玲.Web垂直搜索引擎实现过程的研究[J].现代电子技术,2016,39(08):55-59+63. DOI:10.16652/j.issn.1004-373x.2016.08.015.

[4]杜明卉.面向美食的垂直搜索引擎的设计与实现[D].吉林大学:2018.

[5]张振华.基于lucene的垂直搜索引擎研究[D].吉林大学:2018.

[6]秦杰,宋金玉,张广星.基于Lucene的本地搜索引擎研究与实现[J].计算机科学,2014,41(S2):368-370+407.

[7]段春茜.融合知识图谱和协同过滤的食谱推荐研究[D].中北大学:2021.DOI:10.27470/d.cnki.ghbgc.2021.000821.

[8]熊忠阳,牙漫,张玉芳.基于网页正文结构和特征串的相似网页去重算法[J].计算机应用,2013,33(02):554-557.

二、主要研究内容（说明研究课题的具体内容及课题的新颖性，并明确重点解决的科学问题及预期结果）、

2.1 具体内容

搜索引擎的基本架构如图 1 所示，简单来说，搜索引擎是由爬虫从互联网上爬取资源，再由索引器对所爬取的数据分析并进行索引；在进行检索服务时，使用查询器接收用户输入的关键词，对关键词进行分析，检索索引库，查找出相关数据。本系统实现垂直搜索引擎，则是实现这些搜索引擎基本组件。

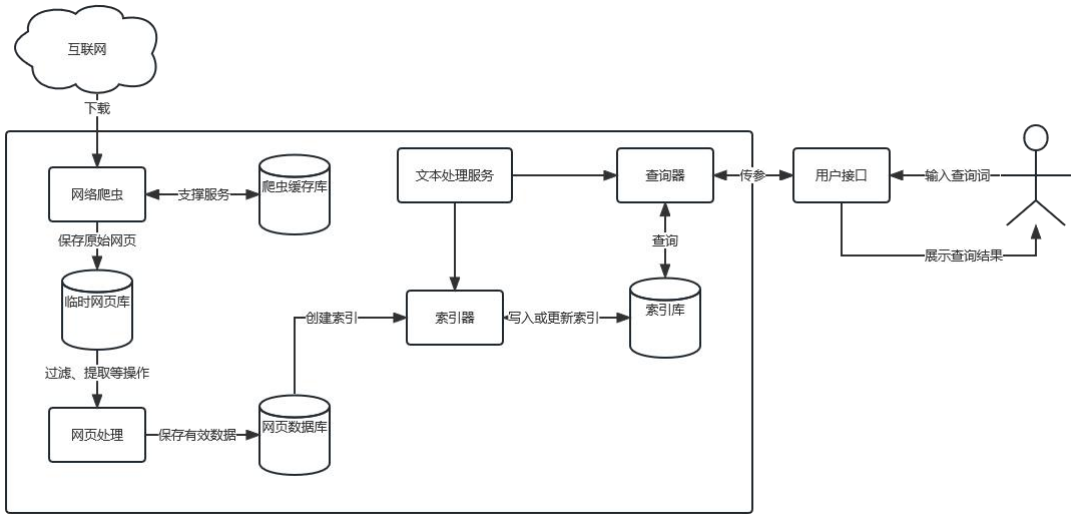


图 1　搜索引擎基本架构图

本系统的主要内容，是搭建一个系统，对于后台管理员而言，管理员可以通过简单的配置，例如爬虫如何获取菜谱数据、如何发现的 URL、运行时的参数等，创建爬虫任务，同时能够对爬虫任务进行增删改等操作。同时能够对多个爬虫进行集中的管理、监控、操作等。对于爬虫爬取的数据，使用 Lucene 的框架的倒排索引进行索引，并提供对索引的管理，同时根据 Lucene 提供相关的方法，设计出提供检索的 api，并在前端中提供用户接口，供用户对菜谱数据进行检索。

2.1.1 实现通用爬虫

要实现一个后台用户通过相关配置，即可运行的面向食谱的垂直爬虫，需要对爬虫进行通用化、垂直化的设计。

实现通用爬虫前，需要对相关的配置设计相关的数据结构，以提供爬虫进行使用，需要设计的配置内容如下：

（1）如何在页面中提取所需的食谱数据。

（2）如何判断当前页面的 URL 为目标页面的 URL，如何从目标页面中提取所需的食谱数据，又如何从页面中发现新的 URL，以供爬虫不停的运行，同时尽可能爬取某个站点的所有食谱数据。

（3）爬虫运行时的参数，例如爬取的间隔时间、线程数、对于失败页面的重新尝试次数、对于失败页面的等待时间等。

（4）爬虫任务的基本信息，如爬虫名、爬虫 id、爬虫描述等。

除了将上述设计成合适的数据结构，还需要选取合适的爬虫框架，使用这些数据结构。大多数爬虫都有成熟的架构，存在多个组件处理专门的任务，因此需要选取合适的爬虫框架，对框架内的组件对如上配置相关的数据结构进行使用，结合爬虫框架各组件的运行流程，设计出通用组件，实现对爬虫的通用化设计。

选取爬虫框架的层面上，其中 Java 的 WebMagic 爬虫框架由国人设计，参考了最典型的爬虫框架 Scrapy，其架构也是代表了爬虫的典型架构，其架构图 2 所示。

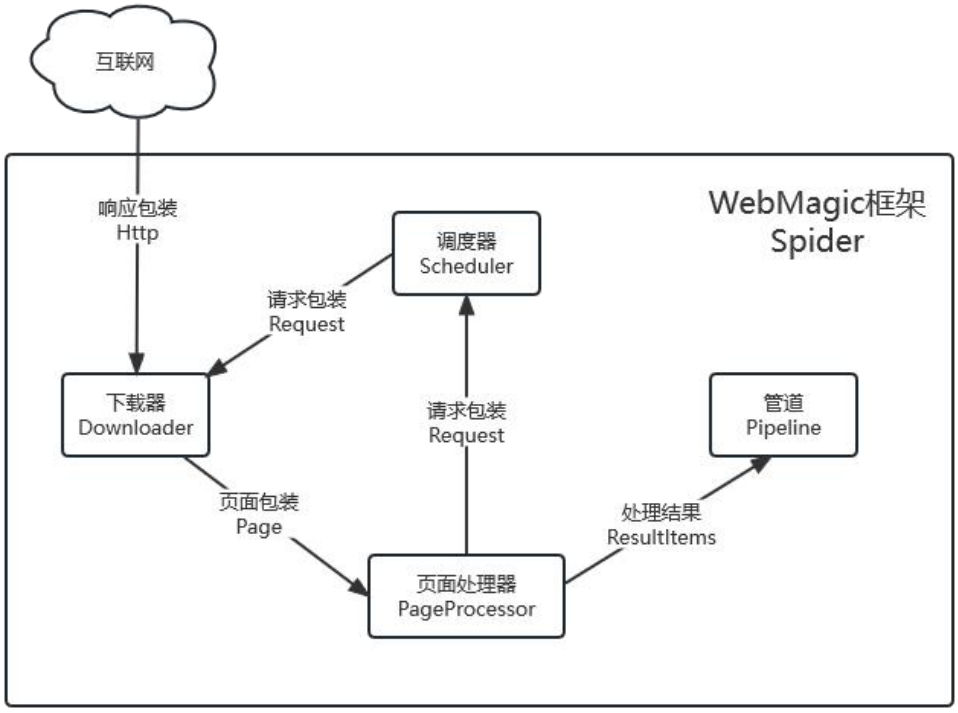


图 2　WebMagic 框架架构图

本系统所爬取的数据是结构化的数据，对应食谱数据模型，该框架跟 Scrapy 一样，非常合适爬取结构化数据，最主要的是设计 PageProcessor 组件，在该组件中可以实现对 HTML 页面进行处理，例如对食谱数据的提取、发现新的 URL 等在页面

中提取信息的操作。对于 Pipeline 组件的设计，可以对爬取的数据进行包装并持久化到数据库。

2.1.2 实现爬虫容器

为了对爬虫进行监控和管理，需要设计一个爬虫容器，任何爬虫实例都需要进入爬虫容器，才能进行运行。爬虫容器能够作为一个后台模块，可以在后台系统对爬虫容器中的注册的爬虫实例进行开始、停止、销毁实例、查看缓存等操作。这也是需要依赖爬虫框架是否提供可监控的模块，为了实现这个模块，选取合适的爬虫框架、对爬虫框架进行深度的学习是很有必要的。

2.1.3 索引、查找

搜索引擎之所以对于大量数据的检索速度非常快，是由于使用了倒排索引，倒排索引的建立，需要对被索引的文本进行分词，分词的结果为词项，再以词项为索引，被索引的文本的唯一编号为被索引项，建立索引。建立这样的索引，Lucene 提供了很好的应用支持。同时 Lucene 自带存储索引的索引库，只需要将被索引的文本作为文档，导入到索引库，再设置相关的垂直化设计，例如使用面向食谱的词库构建分词器作为配置，定制垂直化的 Lucene 进行索引。同时检索器，Lucene 也提供了支持，也同样在设计时进行垂直化的设计。

2.1.4 搭建后台系统

搭建本系统的主要是为了方便后台用户可以通过简单的配置，即可运作搜索引擎。因此需要设计后台系统，提供相关的用户接口，与应用支持层的通用爬虫、爬虫容器、Lucene 索引进行交互。

2.1.5 用户接口

用户能够通过用户端，在搜索框中输入查询词，即可对食谱信息进行检索。除了检索功能，可以考虑帮助用户检索的其他用户端功能，例如食材仓库，能够存储用户所拥有的食材，在搜索时，可以直接基于食材仓库，再根据用户的需求，进行索引，实现按用户所拥有的食材检索菜谱的功能。

2.2 创新点

2.2.1 垂直搜索引擎的应用上的创新

美食主题是在很多公共平台是热议的主题，载体众多，信息量大，信息来源广泛，可以说形成了一个领域，但这类信息缺乏实用的检索技术，为了便于检索对这

些信息进行整合，并实现垂直搜索引擎。

2.2.2 爬虫模块实现监控

创建爬虫实例后，不仅仅能操控爬虫的开始、停止，还能监控爬虫的运行状态，防止爬虫出现不可控制的问题能够及时发现，方便后台管理员进行运行维护。

2.2.3 以用户为中心

相较于传统的食谱网，本搜索引擎以用户为中心，为用户的实际情况考虑，可以根据用户已有的食材，提供用户可制作的食谱，也能提供潜在的可制作食谱。

同时用户的需求是复杂多样的，本搜索引擎也提供了条件组合检索功能。旨在为用户找到所需的最贴切的信息。

三、研究方案（研究方法、研究工作的总体安排和进度，理论分析、计算、实验方法和步骤及其可行性，可能遇到的问题及解决办法）

3.1 研究方法

（1）方法论：

文献研究法、经验总结法、实证研究法。

（2）软件开发方法：

传统软件工程的开发方法，即：需求分析→可行性分析→概要设计→详细设计→编码→测试。

3.2 总体安排和进度

表 1 总体安排表

时间段	任务安排
10 月 25 日-11 月 25 日	项目调研，需求分析，调研项目可行性
11 月 25 日-12 月 25 日	学习搜索引擎的基本原理以及相关技术，了解搜索引擎相关处理细节，了解目前存在的爬虫框架，了解 Lucence 的使用。编写开题报告
12 月 25 日-次年 1 月 25 日	对项目进行概要设计、技术选型
1 月 25 日-2 月 25 日	对项目进行系统设计、详细设计，对项目进行初步开发
2 月 25 日-3 月 25 日	对项目进行开发，中期考核
3 月 25 日-4 月 25 日	对项目进行系列测试（功能测试、性能测试等），撰写毕业论文
4 月 25 日-5 月 10 日	完成毕业论文，并对毕业论文勘误，提交毕业论文

3.2 可能遇到的问题

（1）爬虫如何发现新的网页：从提供的种子 URL 的网页开始，提取其中含有的超链接，访问即可。即通过一个页面的超链接引用关系，发现新网页。

（2）爬虫的道德责任和法律责任：对于网站而言，需要考虑其根目录下

robots.txt，评估哪些资源能爬，哪些不能爬。同时，控制好网络爬虫的爬取频率，同时对爬虫的有严格的监控（依赖于爬虫监测模块的）。

（3）单机爬虫编历策略：根据网页中存在的超链接，利用网页引用其他网页的关系，对整个互联网进行建模，并提取核心内容。其实万维网就是以一个网页 URL 为结点，一个网页引用（或指向）另一个网页作为二元关系的有向无环图。选择爬取策略，就是使用合适的遍历算法对各结点进行充分的遍历。其中有深度优先算法、和广度优先算法，且各有利弊。

深度优先算法策略缺点：

①单站点的网页爬取不充分：对某一网站的网页爬取不充分，容易从一个网站的网页跳到另一个网站的网页，不偏好对一个网站的所有网页爬取完成再去跳到其他站点。

②条件判断复杂，性能差：假如遍历到叶子结点后并不返回顶结点，而是使用回溯策略。需要进行三次判断：这个结点访问过了吗？上一个结点是什么？还有没有可访问的结点？

广度优先算法策略优点：

①相对与深度优先算法策略，不需要进行复杂的判断，发现完同层新结点后，直接访问同层次结点即可。

②偏好上，先爬取的网页重要性高：对于同一个网站而言，该遍历策略往往先爬取外层网页，再爬取内层网页。其中越接近主页的网页，重要性越高。

因此算法的选择上，根据两者的优缺点，使用混合的爬取策略。其中相同站点内网页使用深度优先算法，不同站点采取广度优先算法。

（4）如何识别出内容雷同的网页：通用方法是将网页转换为文档指纹（如特征向量），抛弃无关紧要的信息，然后再使用文档指纹进行比对来判断网页是否重复。涉及的算法有 Bloom Filter 算法 、Shingling 算法、I-Match 算法、SimHash 算法、SpotSig 算法。这些都需要去学习，并选择合适的算法。

（5）所采集到的数据量的庞大，存在电脑硬盘空间不足以支持的风险：从技术上可以学习相关数据压缩算法，或者对采集的信息清除冗余。从硬件上可以考虑购买硬件，扩展硬盘空间；或者迁移到云服务器上运行。这种需要根据爬虫的实际情况，评估数据规模，评估风险。

（6）如何判定食谱页面质量：食谱页面天然就具有可评价的指标，例如点赞、评论、作者的粉丝量等，不像通用搜索引擎需要通过页面的外部链接的指向关系（网页拓扑结构）来判断其重要性。但是这里有个问题，不同网站的食谱质量怎么横向对比？怎么归一化？这是需要学习的，通过相关文献，可以利用相关的推荐算法知识可以解决。也可以在搜索引擎的层面，利用用户点击行为来实现，这些都是需要学习的。

四、指导教师意见

选题有一定实用价值，方案可行，进度合理，准予开题。

校内指导教师签名：　　校外指导教师签名：

2022 年 12 月 1 日　　2020 年 12 月 1 日